

CÂU 2

Employee Attrition Prediction

Dự đoán nhân viên có khả năng nghỉ việc để HR chủ động giữ chân nhân sự với Mô hình Logistic Regression và Random Forest Regressor



Agenda

01

Overview

02

Business Problem

03

Data Quality &
Preprocessing

04

EDA

05

Build Model
(Google Bigquery)

06

Model Comparison

07

Conclusion

08

Business Insight +
Recommendation

1. Overview

Dataset HR dùng để dự đoán nhân viên “Stayed” hay “Left”

74,498
records

23
raw variables

Attrition
target: Stayed / Left

80 / 20
train / test split

Feature	Ý nghĩa	Type
Age	Tuổi nhân viên	Numeric
Gender	Giới tính	Category
MonthsInCompany	Thời gian làm việc tại công ty	Numeric
MonthlyIncome	Thu nhập hàng tháng	Numeric
WorkLifeBalance	Mức độ cân bằng công việc/cuộc sống	Category
JobSatisfaction	Mức độ hài lòng công việc	Category
JobLevel	Cấp bậc công việc	Category
RemoteWork	Có/không làm việc từ xa	Category
Attrition	0 = Stayed, 1 = Left	Target

2. Business Problem



Business Problem

- Attrition làm tăng chi phí tuyển dụng, đào tạo và mất kiến thức nội bộ
- HR thường phát hiện nhân viên muốn nghỉ quá muộn, khi cơ hội giữ chân đã thấp
- Cần một mô hình cảnh báo sớm để ưu tiên can thiệp nhóm có rủi ro cao



Objective

- Xây dựng mô hình classification dự đoán Attrition từ dữ liệu nhân sự
- Dùng Google BigQuery ML để train model và xuất prediction probability
- Đánh giá bằng Accuracy, Precision, Recall, F1 và ROC-AUC; ưu tiên Recall nhóm Left

3. Data Quality

- Raw Data: 74,498 rows
- Observe thấy 0 missing values trên toàn bộ các biến

0
missing values


0
missing target

22
columns after cleaning

14,900
test predictions

Check	Finding	Action
Missing values	0 nulls across all columns	No imputation required
Target quality	Attrition = Stayed / Left	Encode: Stayed → 0, Left → 1
ID & temp columns	Employee ID + EDA bins not useful for model	Drop before training
Column names	Many columns contain spaces/special characters	Rename for BigQuery SQL
Output files	train_cleaned.csv & test_cleaned.csv	Ready to upload to BigQuery

Preprocessing



Rename Dictionary for BigQuery


Months at Company → **MonthsInCompany**
Job Role → **JobRole**
Monthly Income → **MonthlyIncome**
Work-Life Balance → **WorkLifeBalance**
Performance Rating → **PerformanceRating**
Distance from Home → **DistanceFromHome**

Final Modeling Dataset

Output	Shape	Purpose
train_cleaned.csv	59,598 × 22	Train model
test_cleaned.csv	14,900 × 22	Predict / validate
bigquery_predictions.csv	14,900 × 8	Model output


4. EDA – Distribution Overview

Tìm hiểu cấu trúc nhân sự trước khi phân tích Attrition




Phân bố Độ tuổi (Age)

Age phân bố khá rộng từ 18–59, không bị lệch quá mạnh nên phù hợp làm input cho model



Thâm niên (Months at Company)

Tập trung nhiều ở nhóm tenure thấp/trung bình; nhóm mới vào công ty cần theo dõi kỹ



Thu nhập (Monthly Income)


Có dải rộng, median khoảng 7.3k; cần kiểm tra nhóm lương thấp/trung bình trong prediction



Chất lượng dữ liệu: Các biến numeric không có missing, không cần imputation trước khi đưa vào BigQuery ML

EDA – Key Attrition Drivers


Rủi ro nghỉ việc tập trung ở nhóm ít ràng buộc và trải nghiệm công việc chưa tốt



Single

66.78% Left


Nhân sự độc thân có khả năng rời đi cao nhất



Entry Level

63.27% Left

Nhóm mới vào nghề cần lộ trình phát triển rõ



Poor Work-life Balance


60.18% Left

Work-life balance yếu là tín hiệu cảnh báo mạnh

□ **Interpretation:** Attrition không chỉ đến từ lương, mà còn đến từ mức độ gắn kết cá nhân, cấp bậc và trải nghiệm cân bằng công việc

EDA – Work Environment Signals


Điều kiện làm việc và danh tiếng công ty tạo khác biệt rõ về Attrition



Remote Work

- No remote: **52.84% Left**
- Remote: **24.71% Left**


☐ Hybrid/remote policy có thể giảm nguy cơ rời đi.



Overtime

- Overtime = Yes: **51.49% Left**
- Overtime = No: **45.53% Left**

☐ Cần kiểm soát workload và burnout




Reputation

- Poor reputation: **56.02% Left**
- Good reputation: **43.00% Left**

☐ Employer branding tác động retention

5. Build Model — Google BigQuery

PIPELINE



MODEL 1: LOGISTIC REGRESSION


```
CREATE OR REPLACE MODEL
`project-chauhongyennhi-2025.DA04.train_cleaned_logistic_reg_model`
OPTIONS (
  MODEL_TYPE = 'LOGISTIC_REG',
  INPUT_LABEL_COLS = ['Attrition'],
  AUTO_CLASS_WEIGHTS = TRUE -- Tự động cân bằng class nếu tỷ lệ có
                             lệch nhẹ
) AS
SELECT *
FROM `project-chauhongyennhi-2025.DA04.train_cleaned`;
```

MODEL 2: BOOSTED TREE CLASSIFIER


```
CREATE OR REPLACE MODEL
`project-chauhongyennhi-2025.DA04.train_cleaned_boosted_tree_model`
OPTIONS (
  MODEL_TYPE = 'boosted_tree_classifier',
  INPUT_LABEL_COLS = ['Attrition'],
  AUTO_CLASS_WEIGHTS = TRUE,
  MAX_ITERATIONS = 50,
  TREE_METHOD= 'HIST'
)
AS
SELECT * FROM `project-chauhongyennhi-2025.DA04.train_cleaned`;
```

Model Performance

CONFUSION MATRIX



ROC-AUC CURVE





KEY PERFORMANCE METRICS

Metric	Value
Accuracy	0.7471
F1-score	0.7451
Recall Left	0.7727
Precision Left	0.7193
ROC-AUC	≈ 0.8393

- ☐ **Chọn mô hình Logistic Regression:**
- Logistic Regression bắt được ~77.3% nhân viên thực sự nghỉ việc
 - Đạt ROC-AUC 0.8393 - phù hợp mục tiêu HR Early Warning System

Prediction & Validation



Proposed Rules

High Risk (Probability $\geq 70\%$)

□ **Action:** Stay Interview trong vòng 2 tuần

Medium Risk (40% – 70%)

□ **Action:** Manager check-in + thực hiện engagement survey

Low Risk (< 40%)

□ **Action:** Duy trì các chính sách và phúc lợi hiện tại

Validation

- **Confusion Matrix:** Minh chứng rõ ràng cho thấy model có khả năng phân loại và dự đoán tốt cả 2 nhóm Stayed/Left
- **Boxplot & Age Density:** Giúp trực quan hóa đặc lực giúp HR thấu hiểu sâu sắc profile của nhóm nhân sự bị cảnh báo rủi ro
- **Role/Gender Chart:** Cơ sở vững chắc giúp HR tối ưu hóa và ưu tiên phân bổ nguồn lực can thiệp hiệu quả theo từng nhóm đối tượng

6. Model Comparison

Model	Vai trò	Ưu điểm	Decision
Logistic Regression	Final model	Accuracy 0.7471 Recall Left 0.7727 F1 0.7451 ROC-AUC 0.8393	Chọn: metric nhìn hơn + dễ giải thích cho HR
Boosted Tree	Benchmark model	Accuracy 0.7455 Recall Left 0.7638 F1 0.7416 ROC-AUC 0.8351	Không chọn: phức tạp hơn nhưng không outperform Logistic
Decision rationale	Business fit	Với HR Attrition, Recall Left quan trọng vì cần giảm bỏ sót nhân viên có nguy cơ nghỉ việc	Logistic thắng nhẹ ở 5/6 metrics; Boosted Tree chỉ nhìn Precision rất nhỏ

Conclusion:

- 2 model gần như tương đương, nhưng Logistic Regression được chọn vì ROC-AUC, Recall, F1 và Log Loss nhìn hơn nhẹ
- Với bối cảnh HR, model đơn giản hơn nhưng giải thích tốt hơn sẽ dễ triển khai thành Early Warning System

7. Conclusion

Technical

- Logistic Regression là final model vì đạt performance tổng thể nhỉnh hơn Boosted Tree
- ROC-AUC = 0.8393, F1-score = 0.7451, Recall Left = 0.7727
- Model dễ giải thích, phù hợp để HR hiểu các yếu tố rủi ro và triển khai cảnh báo sớm

Business

- Attrition risk tập trung ở nhóm Single, Entry Level, Poor/Fair WLB và No Remote Work
- Model có thể dùng như Early Warning System để ưu tiên Stay Interview
- Không dùng model như quyết định nhân sự tự động; dùng để hỗ trợ HR ra quyết định

Final Model

Logistic Regression

Key Drivers

**Single + Entry + Work-life
Balance**

Use Case

HR Early Warning

8. Business Insight + Recommendations

Insights

- **Single & Entry Level:** Có attrition rate cao nhất → cần career path và mentoring rõ.
- **Remote Work = No:** Có tỷ lệ nghỉ việc cao hơn rất nhiều so với nhóm làm Remote.
- **Work-Life Balance:** Mức Poor/Fair báo hiệu nguy cơ burnout, cần theo dõi workload.
- **Yếu tố phụ trợ:** DistanceFromHome và MonthlyIncome giải thích rõ nhóm rủi ro.

Recommendations

- **Tích hợp hệ thống:** Đưa model vào HRMS để tự động quét risk score mỗi quý.
- **Stay Interview:** Ưu tiên thực hiện ngay với nhóm có xác suất nghỉ việc ≥ 70%.
- **Chính sách Hybrid:** Thiết kế chế độ làm việc linh hoạt cho nhóm ở xa công ty.
- **Chính sách đãi ngộ:** Rà soát lại lương và phụ cấp cho nhóm high-risk hiệu suất tốt.

Employee Segment	Risk Indication	Suggested Action
Single + Entry Level	Highest risk / low attachment	Mentoring + career path 6–12 months
No remote + long commute	High risk / mobility painpoint	Hybrid policy + commute support
Poor Work-life Balance + Overtime	Burnout risk	Workload review + manager check-in
High performer + prob_left ≥ 70%	Talent loss risk	Stay Interview + personalized retention offer

**Thank
you.**

