

Health Insurance Cost Prediction

*Dự đoán phí bảo hiểm y tế với Mô hình Linear Regression và
Random Forest Regressor*

Agenda

01

Overview

02

Business Problem

03

Data Quality &
Preprocessing

04

EDA

05

Build Model
(Google
Bigquery)

06

Model
Comparison

07

Conclusion

08

Business Insight +
Recommendation

1. Overview

7

biến trong dataset

6

features đầu vào

charges

biến mục tiêu

80/20

train/test split

Feature	Ý nghĩa	Type
age	Tuổi người được bảo hiểm	Numeric
sex	Giới tính	Category
bmi	Chỉ số cơ thể BMI	Numeric
children	Số con / người phụ thuộc	Mixed Numeric
smoker	Tình trạng hút thuốc	Category
region	Khu vực sinh sống	Category
charges	Chi phí bảo hiểm y tế	Target

2. Business Problem

Business Problem

- Chi phí bảo hiểm biến động mạnh giữa các nhóm khách hàng
- Nếu định giá cùng một mức phí, công ty có thể **underprice** nhóm rủi ro cao hoặc **overprice** nhóm rủi ro thấp
- Cần một mô hình dự đoán charges để hỗ trợ pricing, và quản trị rủi ro

Objective

- Xây dựng mô hình hồi quy dự đoán **charges** từ tuổi, BMI, số con, smoker, sex và region
- So sánh Linear Regression với Random Forest Regressor
- Chọn mô hình tối ưu dựa trên **MAE, RMSE và R^2**

3. Data Quality

Raw Data: 1,338 rows, 7 columns. Tồn tại vấn đề missing value tại biến children (106 missing = 7.93%)

1
duplicate removed


106
missing children

7.93%
missing rate

0
missing target

Check	Finding	Action
Duplicate	1338 → 1337 rows	Drop duplicates
Missing values	Only children has 106 nulls	Impute with mode = 0
Data type	children dạng text hỗn hợp	Normalize to integer 0–5
Target quality	charges đầy đủ, numeric	Ready for regression
Categorical features	sex, smoker, region	One-Hot Encoding

Preprocessing



Children Cleaning Logic



- no kids / none / 0 → 0
- one / 1 girl / 1 boy → 1
- two / three / four / five → 2-5
- compound text như “1 boy & 2 girls” → Cộng tổng số con

Final Modeling Dataset

- 1,337 records sạch
- Numeric: age, bmi, children
- Categorical encoded: sex, smoker, region
- Train/Test split: 80/20

4. EDA

Distribution Overview



Key findings

Charges

Lịch phí mạnh mẽ; đa số chi phí ở mức thấp nhưng có một số ít trường hợp cực kỳ cao

BMI

Mật độ tập trung cao quanh giá trị 30, cận kề và chạm ngưỡng béo phì



Age

Phân bố tương đối đồng đều, trải dài ổn định từ 18 đến 64 tuổi

Smoker

Chiếm tỷ lệ thiểu số nhưng là nhân tố có ảnh hưởng lớn nhất làm đẩy cao chi phí

What Drives Insurance Charges?



Key findings

Smoker Impact

Người hút thuốc có mức chi phí (charges) cao vượt trội so với nhóm không hút thuốc ở mọi nhóm so sánh.



BMI & Smoker Interaction

Khi chỉ số BMI ≥ 30 kết hợp với hút thuốc (smoker = yes), chi phí y tế có xu hướng tăng vọt và vượt mốc \$40,000.

Demographics

Giới tính (sex) và khu vực địa lý (region) không tạo ra sự khác biệt rõ rệt về mặt thống kê đối với giá trị trung vị của chi phí.

Correlation & Feature Signals



Key findings

Tương quan Tuyến tính (Linear Correlation)

Tuổi (age) có tương quan tuyến tính vừa với chi phí (≈ 0.30), trong khi chỉ số khối cơ thể (bmi) thể hiện tương quan yếu hơn (≈ 0.20)

Tín hiệu Phi tuyến & Quan trọng nhất

Biến smoker (hút thuốc) là tín hiệu mạnh nhất. Do có sự tương tác phi tuyến phức tạp với BMI, cần sử dụng mô hình phù hợp để tối ưu hiệu năng dự đoán

5. Build Model (Google Bigquery)

LINEAR REGRESSION

```
CREATE OR REPLACE MODEL
`project-chauhongyennhi-2025.DA04.insurance_linear_model`
OPTIONS(
  model_type='linear_reg',
  input_label_cols=['charges']
)
AS
SELECT age, sex, bmi, children, smoker, region, charges
FROM `project-chauhongyennhi-2025.DA04.insurance_cleaned`;
```

RANDOM FOREST

```
CREATE OR REPLACE MODEL
`project-chauhongyennhi-2025.DA04.insurance_boosted_tree`
OPTIONS(
  model_type='boosted_tree_regressor',
  input_label_cols=['charges']
)
AS
SELECT age, sex, bmi, children, smoker, region, charges
FROM `project-chauhongyennhi-2025.DA04.insurance_cleaned`;
```

6. Model Comparison

Model	MAE	RMSE	R ²
Linear Regression	4,177	5,956	0.8069
Random Forest	2,633	4,698	0.8799




Interpretation

✓ R² tăng từ 80.69% lên 87.99%, mô hình giải thích tốt hơn biến động chi phí.

✓ MAE giảm khoảng 37%; RMSE giảm khoảng 21% so với Linear Regression.


✓ Random Forest nắm bắt hiệu quả các **pattern phi tuyến phức tạp**: smoker × BMI × age.

→ Mô hình Random Forest vượt trội rõ rệt, giảm đáng kể sai số dự đoán và tối ưu hóa chi phí bảo hiểm



Prediction & Validation


Actual vs. Predicted Insurance Charges (Random Forest)



Actual vs. Predicted

- Actual vs Predicted nằm gần đường 45° → **Mô hình dự đoán tốt ở đa số quan sát**
- Các điểm charges rất cao vẫn là vùng khó dự đoán, **cần theo dõi outlier/risk group**

Biểu đồ phân phối phần dư / sai số dự đoán (Residuals Distribution)



Phân tích sai số (Residuals Distribution)

- Residuals tập trung quanh 0 → **Sai số không lệch một chiều rõ rệt**

7. Conclusion



Technical

- **Random Forest Regressor** được chọn làm mô hình triển khai cuối cùng với hiệu suất cao ($R^2 = 0.88$, $MAE = \$2,633$)
- **Model phi tuyến** phù hợp với pattern của dữ liệu insurance, nơi rủi ro tăng mạnh theo tổ hợp hành vi và sức khỏe. Linear Regression chỉ hữu ích làm baseline



Business

- **Chi phí bảo hiểm** không nên định giá theo demographic đơn giản như giới tính (sex) hoặc khu vực (region)
- **Cần ưu tiên phân tầng rủi ro** theo smoker status, BMI và age. ML đủ độ tin cậy để hỗ trợ underwriting, pricing và cảnh báo rủi ro bồi thường cao

→ Chọn Random Forest Regressor làm mô hình để xuất triển khai.

Final Model

Random Forest

Key Driver

Smoker + BMI

Use Case

Pricing Risk

8. Business Insight & Recommendations

Insights

Không nên định giá bảo hiểm theo một mức chung cho mọi khách hàng.

- **Smoker** là tín hiệu rủi ro mạnh nhất; BMI 30 làm chi phí tăng mạnh
- **Age** làm chi phí tăng ổn định; phù hợp để phân tầng risk theo độ tuổi
- **Sex & Region** không nên là trọng tâm vì khác biệt không rõ ràng



Recommendations

- **Xây dựng risk score** dựa trên age, BMI, smoker, children
- **Thẩm định sâu** nhóm smoker + BMI 30 và thiết kế premium phù hợp
- **Chương trình wellness**: cai thuốc, kiểm soát cân nặng, khám định kỳ
- Ứng dụng Machine Learning để tự động hóa thẩm định, dự báo chi phí bảo hiểm và tối ưu quản lý rủi ro
- **Xây dựng các gói bảo hiểm cá nhân hóa** theo mức độ rủi ro của từng khách hàng



Đề xuất các gói bảo hiểm theo mức độ rủi ro

CUSTOMER SEGMENT	RISK INDICATION	SUGGESTED ACTION
Non-smoker + BMI normal	Low / medium risk	Standard pricing
Older age + BMI high	Medium / high risk	Health check + adjusted premium
Smoker + BMI 30	Highest risk	Deep underwriting + premium loading

The background of the slide features a series of overlapping, flowing, wave-like shapes in various shades of light blue and white. These shapes create a sense of movement and depth, resembling stylized water or smoke. The colors are soft and pastel, contributing to a clean and modern aesthetic.

Thank you.