

Wine Clustering

Phân cụm rượu vang bằng K-Means, PCA và BigQuery



Agenda

01

Overview

02

Business Problem
& Objective

03

Data Quality &
Preprocessing

04

EDA

05

Build Model
(Google Bigquery)

06

Model Evaluation

07

Conclusion

08

Business Insight +
Recommendation

1. Overview

178

Mẫu rượu

13

Features hóa học

0

Target label

K-Means


Unsupervised model

55.41%

Variance PC1 + PC2

Feature group	Biến đại diện	Business meaning
Alcohol / Color	Alcohol, Color_Intensity, Hue	Độ đậm, màu sắc, cảm nhận vị giác
Acidity / Ash	Malic_Acid, Ash, Ash_Alcanity	Độ chua, khoáng chất, cấu trúc nền
Phenols	Total_Phenols, Flavonoids, OD280	Chất chống oxy hóa, body, độ phức tạp
Mineral / Value proxy	Magnesium, Proline	Độ đậm, chất lượng nguyên liệu, phân khúc giá

PCA 2D trước khi phân cụm



Key takeaway

Dữ liệu không có nhãn phân loại sẵn, nên mục tiêu là tìm các nhóm rượu tự nhiên dựa trên cấu trúc hóa học và chuyển hóa thành phân khúc sản phẩm có thể hành động.

2. Business Problem & Objective

BUSINESS PROBLEM

- Doanh nghiệp sở hữu nhiều mẫu rượu với các đặc tính hóa học đa dạng nhưng hiện tại vẫn chưa có nhãn phân khúc rõ ràng
- Việc áp dụng chung một chiến lược định vị đồng nhất có nguy cơ bỏ lỡ nhóm khách hàng cao cấp (premium) hoặc định giá không phù hợp cho phân khúc đại chúng (Mass-market)
- Yêu cầu cấp bách là cần một phương pháp phân cụm khoa học để hỗ trợ hiệu quả cho portfolio strategy, pricing và định vị thương hiệu

OBJECTIVE

- Chuẩn hóa dữ liệu của 13 biến hóa học đặc trưng trước khi tiến hành tính toán khoảng cách bằng thuật toán K-Means
- Phân tích so sánh số lượng cụm tối ưu $K=3$ và $K=4$ thông qua các công cụ đánh giá chuyên sâu: Elbow Method, PCA Scatter và Silhouette Analysis
- Diễn giải chi tiết đặc tính từng cụm thành phân khúc sản phẩm thực tế, từ đó đề xuất các chiến lược hành động kinh doanh cụ thể

3. Data Quality & Preprocessing

- Raw Data: 178 rows, 13 columns
- Không có missing values, không có duplicate
- Vấn đề chính là scale khác nhau giữa các biến nên cần chuẩn hóa trước khi clustering

178
Records


13
Numeric features

0
Duplicates


0
Missing values

Check	Finding	Action
Duplicate	0 records trùng lặp	Không cần drop
Missing values	Tất cả 13 cột đều đủ dữ liệu	Ready for modeling
Data type	Tất cả là numeric	Phù hợp K-Means/PCA
Scale issue	Proline lớn hơn nhiều biến còn lại	StandardScaler
Outlier	Có outliers tự nhiên ở Proline/Alcohol	Giữ lại để phản ánh đặc tính rượu


Preprocessing



Boxplot & outliers




Pairplot overview




4. EDA

Distribution Overview



Correlation Signals



Scale difference

Proline, Magnesium và Color_Intensity có độ phân tán lớn
→ cần scaling trước K-Means

Correlation

Total_Phenols, Flavonoids và OD280 có tương quan thuận mạnh
→ PCA giúp nén thông tin


Outliers

Outliers không phải lỗi dữ liệu mà phản ánh wine style đặc thù, nên được giữ lại

Segmentation signal

Phân phối và tương quan cho thấy dữ liệu có cấu trúc đủ rõ để phân cụm

PCA – Giảm chiều để nhìn cụm rõ hơn



PCA không thay thế mô hình chính

55.4%

Tổng phương sai được giải thích

PC1 đóng góp 36.2% • PC2 đóng góp 19.2%. Tỷ lệ này đủ tin cậy để phục vụ mục đích trực quan hóa dữ liệu

Mô hình phân cụm chính

Thuật toán K-Means vẫn được huấn luyện trực tiếp trên không gian dữ liệu gốc đã scale (đầy đủ 13 biến)

Vai trò thực tế của PCA

Chỉ sử dụng để giảm chiều về 2D/3D nhằm hỗ trợ việc quan sát và đánh giá trực quan độ tách biệt giữa các cụm

Khuyến nghị phân tích

Không đưa ra kết luận phân cụm cuối cùng chỉ dựa trên 2 trục PCA vì chúng không thể giữ lại 100% lượng thông tin

5. Build Model (Google BigQuery)

Model 1: K = 3

```
CREATE OR REPLACE
MODEL `project-chauhongyennhi-2025.DA04.wine_scaled_kmeans_k3`

OPTIONS(
  MODEL_TYPE='KMEANS',
  NUM_CLUSTERS=3,
  STANDARDIZE_FEATURES=FALSE
)
AS
SELECT *
FROM `project-chauhongyennhi-2025.DA04.wine_scaled`;
```

Model 2: K = 4


```
CREATE OR REPLACE
MODEL `project-chauhongyennhi-2025.DA04.wine_scaled_kmeans_k4`

OPTIONS(
  MODEL_TYPE='KMEANS',
  NUM_CLUSTERS=4,
  STANDARDIZE_FEATURES=FALSE
)
AS
SELECT *
FROM `project-chauhongyennhi-2025.DA04.wine_scaled`;
```

Why scaling first?

K-Means dựa trên khoảng cách Euclidean. Nếu không chuẩn hóa, biến Proline/Magnesium sẽ chi phối kết quả và làm méo ranh giới cụm


PCA dùng để quan sát cấu trúc cụm sau preprocessing




6. Model Evaluation I

Elbow + Silhouette Analysis

Biểu đồ Elbow tìm số cụm tối ưu



Biểu đồ Silhouette đánh giá chất lượng cụm (K=3)




Model	Inertia ↓	Silhouette ↑	Calinski ↑	Davies-Bouldin ↓	Interpretability
K=3 (Chọn)	1277.93	0.285	70.94	1.39	High
K=4	1175.43	0.260	56.18	1.80	Medium / Low

✓ Observe:

- **Elbow Method:** Xác định điểm khuỷu tay rõ ràng và thuyết phục nhất tại **K=3**
- **Silhouette:** Giúp cấu trúc phân cụm gọn gàng, sắc nét và dễ giải thích trực quan hơn K=4
- **K=3 được chọn** vì cân bằng tốt nhất giữa metric và khả năng giải thích business

6. Model Evaluation I

Model Comparison (K=3 vs K=4)




Tiêu chí	Mô hình K=3 (Tối ưu)	Mô hình K=4
Ưu điểm	Tách cụm rõ, dễ đặt tên segment; chỉ số silhouette tốt hơn	Có thể phát hiện các micro-segment nhỏ; chỉ số inertia thấp hơn
Nhược điểm	Có thể gộp một vài nhóm nhỏ vào segment lớn	Dễ chia dư; các cụm bị đè/lấn trên PCA; khó giải thích
Business Fit	Tốt: 3 phân khúc rõ ràng, đủ khả năng thực thi hành động	Trung bình: phân khúc quá nhỏ dễ làm rối loạn chiến lược
Ứng dụng	Mô hình chính (Đề xuất)	Chỉ dùng để tham khảo hoặc kiểm tra độ nhạy


→ Chọn K=3 làm mô hình phân cụm cuối cùng vì tối ưu hóa metrics và tránh over-segmentation

Cluster Interpretation


Centroid profile comparison



Alcohol Distribution



Cluster Proportions



Cụm 0

Premium

CHEMICAL PROFILE

Alcohol / Proline / Phenols nổi bật

BUSINESS ROLE

Định vị cao cấp, quà tặng, nhà hàng

Cụm 1

Mass-market

CHEMICAL PROFILE

Nhẹ hơn, cân bằng, dễ uống

BUSINESS ROLE

Mở rộng volume, kênh siêu thị/CVS

Cụm 2

Niche / Blending

CHEMICAL PROFILE

Malic Acid cao, màu/độ chua đặc trưng

BUSINESS ROLE

Limited edition hoặc phối trộn R&D

8. Conclusion

Technical

- **StandardScaler** là bước bắt buộc vì các biến hóa học có thang đo rất khác nhau
- **PCA 2D** giữ được **55.41%** phương sai, đủ để trực quan hóa cấu trúc cụm
- **K=3** được chọn nhờ Elbow, Silhouette và PCA scatter rõ nét hơn K=4

Business

- **3 cụm** có thể chuyển hóa thành **3 phân khúc** sản phẩm: premium, mass-market và niche/blending
- Kết quả giúp doanh nghiệp định vị danh mục, thiết kế thông điệp và **tối ưu hóa kênh phân phối**
- Không nên nhìn dữ liệu rượu chỉ theo từng biến đơn lẻ; cần xem xét **profile hóa học tổng thể**

→ Chọn K-Means với K = 3 làm mô hình phân cụm để xuất triển khai

Final Model

K-Means K=3

Key Method

Scaling + PCA

Use Case

Portfolio Strategy

9. Business Insight & Recommendations

Insights

- Dữ liệu rượu có thể chia thành 3 nhóm sản phẩm rõ hơn sau khi chuẩn hóa
- Premium nên khai thác giá trị chất lượng/cảm nhận đậm vị thay vì cạnh tranh giá
- Mass-market phù hợp chiến lược volume, dễ uống, phân phối rộng
- Niche/blending có thể tận dụng cho R&D, limited edition hoặc food-pairing đặc thù

Recommendations

- Gắn label business cho từng cluster để đội marketing/sales sử dụng nhất quán
- Thiết kế thông điệp, giá bán và kênh phân phối khác nhau cho từng phân khúc
- Theo dõi hiệu quả bán hàng theo cluster để validate phân khúc sau triển khai
- Tái huấn luyện mô hình khi có batch sản phẩm/mùa nho mới

Đề xuất chiến lược theo từng cụm rượu

SEGMENT	POSITIONING	SUGGESTED ACTION
Premium	Cao cấp, đậm đà, hàm lượng chất tốt	Price skimming, kênh nhà hàng/quà tặng, nhấn mạnh chất lượng và trải nghiệm
Mass-market	Dễ uống, nhẹ, dễ tiếp cận	Penetration pricing, phân phối siêu thị/CVS, truyền thông cho beginner
Niche / Blending	Độ chua/màu đặc thù, vị cá tính	Dùng cho blending/R&D hoặc ra phiên bản limited + food pairing

Thank you.

